

Graph Neural Networks

¿Puede una red neuronal aprender a partir de conexiones?

Mauricio Correa · Alejandro Suárez · Verónica Zapata



Red social

Personas conectadas por
amistades

Molécula

Átomos unidos por enlaces
químicos

Internet

Páginas web enlazadas entre
sí

Rutas

Ciudades unidas por
carreteras

El ML clásico asume que cada dato es independiente.

Pero en el mundo real, las relaciones entre entidades son tan importantes como sus atributos.

1736 · Leonhard Euler

El problema de los 7 puentes de Königsberg: ¿se puede recorrer la ciudad cruzando cada puente exactamente una vez? Euler demostró que no, y al hacerlo, fundó la Teoría de Grafos.

$$G = (V, E)$$

Conjunto de nodos (V) conectados por aristas (E)

No dirigido

Relación bidireccional.
(A conoce a B = B conoce a A)

Dirigido

Relación con dirección.
(A sigue a B $\neq$ B sigue a A)

Ponderado / Etiquetado

Aristas con peso o etiqueta.
(distancia, costo, tipo)

¿Por qué el ML tradicional no basta?

03

Independencia de los datos

Asume que cada muestra es independiente e idénticamente distribuida. Las relaciones entre entidades son ignoradas.

Ingeniería de características manual

Requiere que los humanos definan y extraigan features relevantes. Proceso lento y dependiente de expertos.

Escalabilidad limitada

La precisión se estanca aunque se añadan grandes volúmenes de datos. No escala como el deep learning.


Datos no estructurados

Es menos eficiente al procesar datos como imágenes, audio o texto. No aprovecha la estructura del dato.

¿Qué es una GNN?

04

Red neuronal profunda diseñada para datos en forma de grafo.



Redes sociales

Predicción de vínculos y comunidades



Bioinformática

Interacción proteína-medicamento



Recomendación

Grafos de usuario-ítem



Grafos de conocimiento

Representación semántica

Objetivo: aprender un embedding de cada nodo que capture sus atributos y su vecindad.

1 Agregación

Cada nodo recoge mensajes de sus vecinos.

2 Actualización

Combina info recibida con su propio estado.

3 Capas apiladas


Cada capa suma un salto más de alcance (vecinos a 2, 3... saltos).

$$H^{(l+1)} = \sigma(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} W^{(l)})$$

1

Grafos simples


Nodos, aristas, tipos



2

Matriz de adyacencia


Representación matricial



3

Message passing


Ejemplo manual



4

Dataset Cora

Exploración del grafo



5

MLP vs GCN

Entrenamiento



6

Resultados

Comparativa final

Dataset: Cora

Nodo	Artículo científico
Arista	Citación entre artículos
Feature	Palabras del artículo
Clase	Categoría temática
Tarea	Clasificación de nodos

MLP

✓ data.x

✗ data.edge_index


Solo usa las características de cada artículo por separado.

GCN

✓ data.x

✓ data.edge_index

Usa características + conexiones del grafo de citas.



Ambos modelos – overfitting

Train $\approx$ 100%, pero val y test divergen significativamente.

GCN generaliza mejor

Test accuracy +24pp vs MLP. Las citaciones aportan contexto crucial.

Estructura importa

La topología del grafo captura relaciones temáticas entre artículos.

Riesgos

- Sobreajuste (overfitting): visible en Cora con ambos modelos.
- Escalabilidad: grafos muy grandes son costosos computacionalmente.
- Sesgos en el grafo: si las conexiones tienen sesgos, el modelo los hereda.

Conclusión

Una GCN no clasifica nodos de forma aislada: explota atributos y relaciones a la vez. Cora demuestra que la topología del grafo es información, no ruido.

Fuentes

IBM - What is a Graph Neural Network?
ibm.com/think/topics/graph-neural-network

GraphEverywhere - ¿Qué son los grafos?
grapheverywhere.com/que-son-los-grafos

Kipf & Welling (2017) - Semi-Supervised Classification with Graph Convolutional Networks

Dataset Cora - PyTorch Geometric